

Chatbot de Atención al Cliente con Análisis de Sentimientos: Comparación de Modelos de Aprendizaje Automático

Paula Llanos López
Universidad EAFIT
Medellín, Colombia
pillanosl@eafit.edu.co

Samuel Rivero Urribarri
Universidad EAFIT
Medellín, Colombia
seriverou@eafit.edu.co

Sara López Marín
Universidad EAFIT
Medellín, Colombia
slopezm13@eafit.edu.co

Resumen—Los sistemas de atención al cliente automatizados muchas veces no pueden reconocer ni responder bien a las emociones de los usuarios, lo que genera malas experiencias. Este trabajo presenta el desarrollo y evaluación de un chatbot con análisis de sentimientos que clasifica mensajes en tres categorías (positivo, neutral, negativo) y ajusta sus respuestas según la emoción detectada. Comparamos tres algoritmos de aprendizaje automático: Regresión Logística, SVM y Naive Bayes, entrenados con 14,640 tweets del dataset Twitter US Airline Sentiment de Kaggle. Los resultados muestran que el modelo SVM alcanza la mejor exactitud (79.41 %), mientras que Regresión Logística ofrece el mejor equilibrio entre rendimiento (F1 macro: 0.7368, exactitud: 78.45 %) y velocidad (6.85s de entrenamiento). Naive Bayes, aunque más rápido (1.97s), presenta problemas con el desbalance entre clases (F1 macro: 0.5426). El chatbot implementado en Streamlit incluye respuestas que se adaptan según la emoción. Este trabajo muestra que técnicas accesibles de ML pueden crear chatbots emocionalmente inteligentes sin necesitar muchos recursos, ayudando a mejorar la experiencia del usuario en servicios de atención al cliente automatizados.

Index Terms—Chatbot, análisis de sentimientos, atención al cliente, aprendizaje automático, detección de emociones, procesamiento del lenguaje natural, TF-IDF, clasificación de texto.

I. INTRODUCCIÓN

Los chatbots para atención al cliente se han vuelto muy comunes en las plataformas digitales. Sin embargo, la mayoría tienen un problema importante: no pueden reconocer ni responder bien a las emociones del usuario [14]. Esta limitación puede hacer que los clientes se frustren más cuando tienen problemas, dañando la relación con las empresa.

Veamos un ejemplo: un cliente cuyo pedido se ha retrasado escribe: “¡Ya pasaron 3 días y mi paquete NO ha llegado! ¿Qué está pasando?” Un chatbot normal respondería: “Por favor proporciona tu número de orden”, ignorando completamente cómo se siente el usuario. En cambio, un sistema con análisis de sentimientos podría detectar la frustración y responder: “Lamento mucho los problemas con tu entrega. Entiendo tu frustración. Déjame ayudarte inmediatamente. ¿Podrías darme tu número de orden?” Esta diferencia que parece pequeña puede cambiar mucho la experiencia del cliente.

I-A. Motivación y Contexto

El análisis de sentimientos es una técnica de procesamiento de lenguaje natural (NLP) que permite identificar y extraer emociones e información subjetiva de los textos [1], [2]. Aplicarlo en chatbots es un paso natural hacia sistemas más inteligentes y centrados en el usuario.

Desde el punto de vista de las empresas, usar análisis de sentimientos en chatbots trae varios beneficios: mejora la satisfacción del cliente, ayuda a detectar problemas a tiempo, decidir cuándo usar soporte humano, y genera datos sobre cómo se sienten los usuarios. Para estudiantes y desarrolladores, es una oportunidad de aplicar técnicas de ML en un caso real con impacto visible.

I-B. Objetivos del Proyecto

Este trabajo busca responder: ¿Qué modelo de aprendizaje automático clásico (Regresión Logística, SVM o Naive Bayes) ofrece el mejor equilibrio entre precisión y velocidad para clasificar sentimientos en tiempo real en chatbots de atención al cliente?

Los objetivos del proyecto son:

- **Específico:** Entrenar y evaluar tres modelos de clasificación de sentimientos usando el dataset Twitter US Airline Sentiment.
- **Medible:** Lograr F1 macro ≥ 0.70 y exactitud $\geq 75\%$ en las pruebas, con tiempo de respuesta < 2 segundos.
- **Alcanzable:** Usar recursos normales, bibliotecas gratuitas, y datos públicos.
- **Relevante:** Hacer un prototipo funcional con interfaz web que demuestre que funciona en la práctica.
- **Temporal:** Completar todo en el periodo académico establecido.

I-C. Alcance y Contribuciones

El proyecto incluye: (1) comparación rigurosa de tres algoritmos de ML en las mismas condiciones, (2) implementación de chatbot funcional con interfaz Streamlit, y detectar cuando es necesario un humano, (3) análisis de los trade-offs entre exactitud, velocidad y complejidad.

Las principales contribuciones son: evaluación comparativa con los mismos datos y métricas, demostración de que es posible hacer chatbots emocionalmente inteligentes sin muchos recursos, sistema completo y documentado para que otros lo puedan usar, y análisis honesto de limitaciones y qué se puede hacer a futuro.

Limitaciones: El sistema solo funciona con datos de entrenamiento basados en el dataset escogido; clasifica únicamente tres categorías, no detecta sarcasmo ni ironía, y tiene respuestas limitadas para preguntas frecuentes (12 preguntas predefinidas).

II. REVISIÓN DE LITERATURA Y ESTADO DEL ARTE

II-A. Fundamentos de Análisis de Sentimientos

El análisis de sentimientos ha cambiado mucho desde los trabajos iniciales de Pang y Lee [2]. Liu [1] lo define como el proceso de identificar, extraer y medir estados emocionales y opiniones. Se usa en muchas áreas: monitorear redes sociales, análisis financiero y sistemas de recomendación.

Feldman [5] identifica tres niveles: análisis de documento completo, análisis por oración, y análisis por aspecto. Nuestro trabajo se enfoca en mensajes individuales, que es lo apropiado para conversaciones.

II-B. Enfoques Metodológicos

Ravi y Ravi [4] clasifican los métodos de análisis de sentimientos en tres tipos:

1) Basados en diccionarios: Usan listas de palabras con sentimientos pre-asignados. Mohammad y Turney [6] crearon diccionarios grandes usando crowdsourcing. Ventajas: no necesitan entrenamiento, son fáciles de entender. Desventajas: dependen mucho del contexto, no capturan bien las negaciones complejas.

2) Aprendizaje automático clásico: Usan representaciones vectoriales y algoritmos supervisados. Go y Bhayani [3] fueron pioneros en clasificar sentimientos en Twitter. Nuestro trabajo usa este enfoque.

3) Deep Learning: Redes neuronales profundas que aprenden representaciones complejas. Socher [11] introdujo modelos recursivos. Kim [12] popularizó CNNs para clasificar oraciones. Devlin [13] revolucionaron NLP con BERT. Zhang [10] revisa el estado del arte en deep learning para sentimientos.

II-C. Chatbots y Sistemas Conversacionales

Følstad y Brandtzæg [15] identifican tres generaciones de chatbots: (1) basados en reglas (scripts pre-programados), (2) con ML supervisado (clasificadores de intención), y (3) conversacionales avanzados (modelos generativos). Nuestro sistema mezcla las generaciones 1 y 2: usa ML para sentimientos y reglas para preguntas frecuentes.

Xu y otros [14] analizan chatbots en redes sociales e identifican que personalizar según las emociones, lo que mejora la satisfacción del usuario. Esto motivó nuestra implementación de respuestas que se adaptan según el sentimiento detectado.

II-D. Brechas de Investigación

A pesar de los avances, hay vacíos en la literatura:

Trade-off exactitud-velocidad: La mayoría de trabajos recientes se enfocan en maximizar exactitud con modelos complejos, sin considerar las limitaciones de recursos cuando se implementa en pequeña escala.

Comparaciones justas: Pocos estudios comparan varios enfoques con los mismos datos y métricas, lo que dificulta sacar conclusiones generales.

Desbalance de clases: El desbalance natural en datos de sentimientos (más negativos en quejas) no se atiende bien. La mayoría reporta exactitud global sin métricas balanceadas como F1 macro.

Implementaciones prácticas: Hay muchos papers teóricos pero pocos prototipos funcionales con código abierto y documentación completa.

Nuestro trabajo ataca estas brechas con: comparación controlada de modelos con énfasis en trade-offs, uso de F1 macro como métrica principal dado el desbalance.

III. PREGUNTA DE INVESTIGACIÓN Y OBJETIVOS

III-A. Pregunta de Investigación

¿Qué modelo de aprendizaje automático clásico—Regresión Logística, SVM o Naive Bayes—da el mejor equilibrio entre precisión (medida por F1 macro) y velocidad (tiempo de entrenamiento e inferencia) para un chatbot de atención al cliente en tiempo real?

III-B. Objetivos Detallados

Objetivo 1 - Específico: Entrenar tres modelos de clasificación (Regresión Logística, SVM, Naive Bayes) con el dataset Twitter US Airline Sentiment usando representación TF-IDF.

Objetivo 2 - Medible: Alcanzar en las pruebas:

- F1 macro score ≥ 0.70 (métrica principal)
- Exactitud global $\geq 75\%$
- Tiempo de respuesta promedio < 2 segundos
- Tiempo de entrenamiento < 10 minutos en CPU normal

Objetivo 3 - Alcanzable: Implementar con recursos modestos:

- Bibliotecas: scikit-learn 1.3+, NLTK, pandas
- Hardware: CPU multi-núcleo normal (sin GPU)
- Datos: dataset público de Kaggle (14,640 ejemplos)

Objetivo 4 - Relevante: Desarrollar chatbot funcional que:

- Clasifique sentimiento en tiempo real
- Adapte respuestas según emoción detectada
- Sugiera pasar a humano cuando confianza/margen ≥ 0.70
- Responda 10-15 preguntas frecuentes por similitud TF-IDF (threshold 0.45)

Objetivo 5 - Temporal: Completar en 2 semanas:

- Revisión de literatura y análisis exploratorio
- Preprocesamiento y feature engineering
- Entrenamiento y validación de modelos
- Desarrollo de interfaz Streamlit
- Evaluación y análisis de resultados

III-C. Hipótesis de Investigación

H1: SVM lineal alcanzará la mejor exactitud pero será más lento en entrenamiento comparado con Regresión Logística y Naive Bayes.

H2: Regresión Logística ofrecerá el mejor equilibrio entre F1 macro (> 0.72) y tiempo de entrenamiento ($< 10s$), siendo óptima para el chatbot.

H3: Naive Bayes será el más rápido pero tendrá F1 macro más bajo por su asunción de independencia, especialmente afectado por el desbalance de clases.

IV. DATOS Y ANÁLISIS PRELIMINAR

IV-A. Dataset y Procedencia

Usamos el dataset *Twitter US Airline Sentiment* disponible en Kaggle. Contiene 14,640 tweets en inglés sobre aerolíneas estadounidenses. Cada tweet está etiquetado manualmente con su sentimiento.

Por qué lo elegimos: El dominio de quejas de aerolíneas es similar a atención al cliente, el volumen es suficiente para entrenar modelos sin ser demasiado pesado, las etiquetas son de calidad (anotación humana) con poco ruido, y el inglés informal de Twitter representa bien el lenguaje conversacional en chatbots.

IV-B. Variables y Estructura

Variable objetivo (y): `airline_sentiment` $\in \{negative, neutral, positive\}$.

Variable predictora (X): `text` (contenido del tweet).

Prevenir fugas de datos: Excluimos las columnas `airline_sentiment_confidence`, `negativereason`, y `negativereason_confidence`, ya que se derivan directamente de la etiqueta objetivo. También excluimos metadatos (`tweet_id`, `tweet_created`, `user_timezone`).

IV-C. Distribución y Desbalance de Clases

La distribución de clases muestra un desbalance importante:

Cuadro I: Distribución de Clases en Dataset Completo

Clase	Cantidad	Porcentaje
Negative	9,178	62.69 %
Neutral	3,099	21.17 %
Positive	2,363	16.14 %
Total	14,640	100 %

Este desbalance refleja cómo es el dominio: los usuarios tienden a expresarse en redes sociales principalmente cuando tienen problemas (sesgo de negatividad). Por eso usamos **F1 macro** como métrica principal, la cual da el mismo peso a las tres clases sin importar su frecuencia.

IV-D. Análisis Exploratorio de Datos (EDA)

Longitud de mensajes: Los tweets negativos tienden a ser un poco más largos (media: 136 caracteres) que neutrales (121 caracteres) y positivos (119 caracteres). Los usuarios frustrados escriben más cuando se quejan.

Patrones de texto: Palabras frecuentes por clase:

- *Negative:* “flight”, “cancelled”, “delay”, “hours”, “customer”, “service”
- *Neutral:* “thank”, “flight”, “get”, “help”, “time”
- *Positive:* “thanks”, “great”, “service”, “love”, “best”

Elementos especiales: El 73 % de tweets contienen menciones (@usuario), 41 % incluyen URLs, y 18 % tienen hashtags. Aplicamos preprocesamiento para normalizar estos elementos.

Negaciones: Encontramos 2,347 tweets (16 %) con negaciones explícitas (“not”, “no”, “never”, “n’t”). Esto es importante para análisis de sentimientos: “not good” $\neq$ “good”. Por eso usamos TF-IDF.

IV-E. Partición de Datos

Para mantener las proporciones de clases usamos:

- **Entrenamiento:** 80 % (11,712 ejemplos)
- **Prueba (hold-out):** 20 % (2,928 ejemplos)
- **Validación cruzada:** 5-fold estratificada sobre conjunto de entrenamiento
- **Random state:** Fijado en 42 para que sea reproducible

Prevención de fugas crítica: La división train/test se hizo *antes* de cualquier ajuste de vectorizadores TF-IDF. El vocabulario y estadísticas IDF se calcularon solo con el conjunto de entrenamiento.

IV-F. Métrica de Evaluación Principal

Dado el desbalance, usamos **F1 macro score** como métrica principal. F1 macro da el mismo peso a todas las clases, penalizando modelos que ignoran clases minoritarias. Como métrica secundaria reportamos exactitud global, útil para comparar con otros trabajos.

V. MÉTODOS

V-A. Preprocesamiento de Texto

Implementamos un pipeline de limpieza equilibrado entre normalizar y mantener información importante:

Normalización básica:

- Convertir a minúsculas
- Eliminar URLs
- Eliminar menciones: @usuario
- Eliminar hashtags: #palabra
- Normalizar los espacios en blanco

Decisiones importantes:

- **No aplicamos stemming/lemmatization:** Perdían matices (“good” vs “better” vs “best”)
- **Mantenemos signos de puntuación repetidos:** Son indicadores emocionales fuertes (“!!!!”, “:”))
- **No expandimos contracciones:** TF-IDF aprende “can’t” como token informativo

V-B. Validación y Evaluación

Validación cruzada estratificada: 5-fold CV sobre conjunto de entrenamiento para estimar rendimiento generalizable y varianza.

Conjunto de prueba hold-out: 20 % del dataset, sin tocar hasta evaluación final, para estimación imparcial de rendimiento en producción.

Métricas reportadas:

- F1 macro (principal): rendimiento balanceado entre clases
- Exactitud: métrica global para comparar con otros trabajos
- Precision/Recall por clase: diagnóstico de errores específicos
- Matriz de confusión: análisis de patrones de error
- Tiempo de entrenamiento: viabilidad práctica
- Tiempo promedio de inferencia: viabilidad para tiempo real

Pipeline completo: Encapsulamos preprocesamiento + vectorización + clasificador en objetos `Pipeline` de scikit-learn, garantizando que las transformaciones de test usen parámetros ajustados solo en train.

VI. RESULTADOS

VI-A. Rendimiento en Validación Cruzada

La Tabla II muestra resultados de 5-fold CV estratificada sobre el conjunto de entrenamiento (11,712 ejemplos).

Cuadro II: Resultados de Validación Cruzada (5-Fold Estratificada)

Modelo	F1 Macro	Exactitud	Desv. Std.
Log. Regression	0.7381	0.7856	0.0042
Linear SVM	0.7319	0.7914	0.0051
Multinomial NB	0.5261	0.7110	0.0089

Observaciones: Regresión Logística y SVM logran F1 macro similares (0.73-0.74), con SVM un poco mejor en exactitud. Naive Bayes baja mucho en F1 macro (0.5261), mostrando rendimiento desbalanceado entre clases. La desviación estándar baja confirma que los resultados son estables.

VI-B. Rendimiento en Conjunto de Prueba

La evaluación final sobre el conjunto de prueba hold-out (2,928 ejemplos) confirma los hallazgos de validación cruzada. La Tabla III presenta métricas completas.

Cuadro III: Resultados Finales en Conjunto de Prueba

Modelo	F1 Macro	Exactitud	Train (s)	Pred (ms)
Log. Regr.	0.7368	0.7845	6.85	<1
Linear SVM	0.7360	0.7941	5.44	1-2
Multinom. NB	0.5426	0.7186	1.97	<0.5

Análisis de resultados:

- **SVM:** Alcanza la mejor exactitud (79.41 %), validando H1. Sin embargo, su ventaja en F1 macro sobre Regresión Logística es muy pequeña (0.7360 vs 0.7368).
- **Regresión Logística:** Ofrece el mejor F1 macro (0.7368) con tiempo de entrenamiento razonable (6.85s) e inferencia ultra-rápida (<1ms). Confirma H2 como modelo óptimo para equilibrio rendimiento-velocidad.
- **NB:** El más rápido en entrenamiento (1.97s) e inferencia (<0.5ms), pero F1 macro mucho más bajo (0.5426), confirmando H3. La asunción de independencia y el desbalance de clases lo afectan bastante.

VI-C. Análisis por Clase

La Tabla IV desglosa precision, recall y F1-score por clase para cada modelo.

Observaciones importantes:

- **Clase Negative:** Los tres modelos funcionan bien (F1 > 0.82), siendo la clase mayoritaria (62.69 %) con patrones de palabras claros (“cancelled”, “delay”, “worst”).
- **Clase Neutral:** La más difícil para todos los modelos. Regresión Logística logra mejor equilibrio (F1: 0.635). Neutral es difícil porque agrupa consultas informativas sin carga emocional fuerte.
- **Clase Positive:** F1 intermedio (~0.71). Los positivos tienen palabras claras (“thank”, “great”, “love”) pero su baja frecuencia (16.14 %) dificulta el aprendizaje.
- **Naive Bayes con problemas:** Recall de 0.993 en Negative pero colapso en Neutral (0.194) y Positive (0.340). Se enfoca demasiado en la clase mayoritaria, problema empeorado por la independencia condicional.

VI-D. Matrices de Confusión

Las matrices de confusión muestran patrones de error para cada modelo.

Patrones identificados:

- **Confusión Negative-Neutral:** Error más frecuente en Regresión Logística (238 casos) y SVM (177 casos). Muchos tweets informativos sobre problemas son interpretados como negativos por palabras como “delay” o “cancelled” en contexto neutral.
- **Confusión Neutral-Negative:** Segunda más común (128 y 171 casos). Consultas expresadas con un poco de frustración son difíciles de distinguir.
- **Naive Bayes:** Clasifica 486 Neutrals y 285 Positives como Negative, confirmando sesgo extremo hacia clase mayoritaria.


VI-E. Análisis Comparativo y Selección del Modelo

Análisis de trade-offs:


- **Para máxima exactitud:** SVM (79.41 %), bueno para análisis offline o batch processing donde 5.44s de entrenamiento no es problema.
- **Para velocidad máxima:** Naive Bayes (2,500 msg/s), bueno para sistemas de ultra-alto volumen donde se tolera menor F1 macro y sesgo hacia negativos.

Cuadro IV: Métricas por Clase en Conjunto de Prueba


Modelo	Clase	Precision	Recall	F1	Support
Regresión Log.	Negative	0.889	0.833	0.860	1,835
	Neutral	0.579	0.702	0.635	620
	Positive	0.727	0.704	0.715	473
SVM	Negative	0.864	0.880	0.872	1,835
	Neutral	0.610	0.642	0.626	620
	Positive	0.767	0.662	0.711	473
NB	Negative	0.703	0.993	0.823	1,835
	Neutral	0.759	0.194	0.308	620
	Positive	0.915	0.340	0.496	473



(a) Matriz de confusión Regresión Log



(b) Matriz de confusión de SVM



(c) Matriz de confusión de Naive Bayes

Figura 1: Matrices de confusión por modelo.

- **Para equilibrio óptimo: Regresión Logística** (F1: 0.7368, 6.85s train, <1ms latencia). Cumple objetivos y es ideal para chatbot en tiempo real.

VI-F. Implementación del Chatbot

El sistema implementado en Streamlit incluye:

- **Clasificación en tiempo real:** Cada mensaje del usuario se vectoriza con TF-IDF y se clasifica con el modelo seleccionado.
- **Política de respuestas adaptativas:**
 - *Negative:* Inicio empático (“Lamento tu experiencia”). Si confianza/margen ≥ 0.7 (configurable), sugiere pasar a agente humano.
 - *Neutral/Positive:* Inicio informativo estándar.
- **Sistema de preguntas frecuentes:** 12 preguntas comunes. Usa similitud coseno sobre TF-IDF entre mensaje de usuario y FAQs. Si similitud ≥ 0.45 (configurable), retorna respuesta predefinida.
- **Métricas de sesión:** Sidebar muestra latencia promedio por mensaje, útil para monitorear rendimiento, además muestra las matrices de confusión de cada modelo.

Latencia promedio observada: 1.5ms sobre mensajes de prueba, confirmando que funciona bien en tiempo real.

VII. DISCUSIÓN

VII-A. Interpretación de Resultados

Los resultados validan parcialmente nuestras hipótesis:

H1 (Validada): SVM alcanzó la mejor exactitud (79.41 %), superando a Regresión Logística por 0.96 puntos. Sin embargo, la ventaja en F1 macro fue muy pequeña (0.7360 vs 0.7368 a favor de Regresión Logística), sugiriendo que con desbalance, F1 macro es más confiable que exactitud global.

H2 (Validada): Regresión Logística cumplió expectativas como modelo de mejor equilibrio, logrando F1 macro de 0.7368 (objetivo: ≥ 0.70) con tiempo de entrenamiento de 6.85s (< 10s objetivo). Es el modelo óptimo para implementar.

H3 (Validada con matiz): Naive Bayes fue el más rápido (1.97s entrenamiento, <0.5ms inferencia) pero su F1 macro (0.5426) quedó muy por debajo del umbral de 0.70. Sin embargo, su exactitud (71.86 %) no fue mala. El problema está en el sesgo: recall de 0.993 en Negative pero tuvo errores en clases minoritarias.

VII-B. Análisis de Clase Neutral

La clase Neutral fue el mayor reto para todos los modelos (F1: 0.63-0.31). Tres factores contribuyen:

1. **Ambigüedad:** “My flight was delayed 3 hours” es neutral parcialmente pero tiene connotación negativa implícita. La línea entre Neutral-Negative es borrosa.
2. **Desbalance:** Solo 21 % del dataset. Menos exposición durante entrenamiento.
3. **Heterogeneidad:** Neutral agrupa consultas informativas, confirmaciones, y declaraciones sin emoción clara, más diversos que Positive/Negative.

Implicación práctica: En el chatbot, errores Neutral→Negative son conservadores (respuesta empática innecesaria pero no dañina). Errores inversos (Negative→Neutral) son críticos (ignorar frustración real), pero son menos frecuentes (128 casos vs 238 en Regresión Logística).

VII-C. Limitaciones del Estudio

1. **Dominio limitado:** Entrenamiento solo en quejas de aerolíneas. Para usarlo en otros dominios (e-commerce, bancos) hay que validar. Aunque las emociones son universales.
2. **Idioma único:** Datos en inglés. Versión en español del chatbot usa traducción, lo que puede introducir errores. Trabajo futuro: entrenar con datos en español.
3. **Categorías limitadas:** Solo 3 clases (positivo/neutral/negativo). Emociones complejas (sarcasmo, ironía, frustración vs enojo) no se distinguen.
4. **Sin contexto:** Cada mensaje se clasifica independiente. No hay memoria conversacional. Un usuario podría pasar de neutral a negativo, pero el sistema no acumula contexto.
5. **FAQs limitadas:** Sistema basado en similitud TF-IDF a 12 preguntas predefinidas. No generaliza a preguntas fuera de esa cobertura.

VII-D. Aportes del Trabajo

1. **Comparación justa:** Evaluamos tres modelos con los mismos datos, preprocesamiento y métricas, permitiendo conclusiones válidas sobre trade-offs.
2. **Énfasis en F1 macro:** Priorizamos métrica balanceada sobre exactitud global, importante en datos desbalanceados. Poco común en trabajos de chatbots.
3. **Prototipo funcional:** Código completo con interfaz web, no solo paper teórico.
4. **Análisis de viabilidad práctica:** Documentamos no solo exactitud sino tiempos de entrenamiento, latencia, importantes para implementación real.
5. **Transparencia en limitaciones:** Declaramos explícitamente qué NO hace el sistema, evitando exagerar lo que ML puede hacer.

VIII. CONCLUSIONES Y TRABAJO FUTURO

VIII-A. Conclusiones Principales

Este trabajo muestra que es posible construir chatbots con inteligencia emocional básica usando técnicas clásicas de ML:

1. Viabilidad técnica: Los tres modelos evaluados superaron el umbral mínimo de utilidad práctica, con Regresión Logística y SVM alcanzando F1 macro > 0.73 y exactitud $> 78\%$.

2. Modelo óptimo: Regresión Logística resultó ser la mejor opción para chatbots en tiempo real, ofreciendo equilibrio óptimo entre rendimiento (F1: 0.7368), velocidad (6.85s entrenamiento, $< 1\text{ms}$ inferencia), y facilidad de interpretación.

3. Limitaciones de Naive Bayes: Aunque super rápido, Naive Bayes falla con desbalance severo, con sesgo extremo hacia la clase mayoritaria (F1 macro: 0.5426). No lo recomendamos para este problema.

4. Accesibilidad: Con dataset público (14,640 ejemplos), bibliotecas gratuitas (scikit-learn), y hardware normal, mostramos que estudiantes y pequeñas empresas pueden implementar esta tecnología sin barreras.

5. Impacto potencial: Detectar sentimientos permite respuestas empáticas y pasar inteligentemente a soporte humano, con potencial de mejorar satisfacción del cliente y eficiencia operacional.

VIII-B. Trabajo Futuro

VIII-B1. Mejoras a Corto Plazo: 1. Expansión lingüística: Entrenar modelos nativos en español usando datasets como TASS [16] o crear nuestro propio dataset anotado. Eliminar dependencia de traducción.

2. Más datos: Escalar el conjunto de datos a 50.000–100.000 observaciones y diversificar las fuentes para abarcar empresas de múltiples sectores, evitando la concentración exclusiva en aerolíneas.

3. Más categorías emocionales: Pasar de 3 a 6-8 categorías: enojo, frustración, satisfacción, confusión, urgencia, sarcasmo. Requiere re-anotar el dataset.

4. Detección de sarcasmo: Implementar reglas simples (signos de puntuación, emojis contradictorios) o entrenar un clasificador específico de sarcasmo como preprocesamiento.

5. Memoria conversacional: Mantener historial de últimos 3-5 mensajes para detectar si alguien se va poniendo más negativo y adaptar respuestas.

VIII-C. Reflexión Final

El análisis de sentimientos en chatbots no es solo un problema técnico de clasificación, sino un paso hacia sistemas conversacionales más humanos y empáticos. Los resultados de este trabajo muestran que agregar inteligencia emocional básica a chatbots es accesible y práctico.

Sin embargo, la tecnología sola no garantiza mejores experiencias. El diseño de cómo responder (cuándo pasar a humano, cómo expresar empatía sin sonar robótico) es igual de importante. Un sistema que detecta frustración con 95 % de exactitud pero responde como robot puede ser tan frustrante como uno que no detecta nada.

El futuro de los chatbots no está solo en algoritmos más precisos, sino en la integración armoniosa de ML, diseño conversacional, y comprensión profunda de necesidades humanas. Este trabajo es un pequeño paso en esa dirección: mostrar que

con herramientas accesibles, estudiantes y pequeñas empresas pueden contribuir a construir tecnología más humana.

REFERENCIAS

- [1] Liu, B. (2012). Sentiment analysis and opinion mining. *Synthesis lectures on human language technologies*, 5(1), 1-167.
- [2] Pang, B., & Lee, L. (2008). Opinion mining and sentiment analysis. *Foundations and Trends in Information Retrieval*, 2(1-2), 1-135.
- [3] Go, A., Bhayani, R., & Huang, L. (2009). Twitter sentiment classification using distant supervision. *CS224N project report, Stanford*, 1(12), 2009.
- [4] Ravi, K., & Ravi, V. (2015). A survey on opinion mining and sentiment analysis: tasks, approaches and applications. *Knowledge-based systems*, 89, 14-46.
- [5] Feldman, R. (2013). Techniques and applications for sentiment analysis. *Communications of the ACM*, 56(4), 82-89.
- [6] Mohammad, S. M., & Turney, P. D. (2013). Crowdsourcing a word-emotion association lexicon. *Computational intelligence*, 29(3), 436-465.
- [7] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of machine learning research*, 12, 2825-2830.
- [8] Bird, S., Klein, E., & Loper, E. (2009). *Natural language processing with Python: analyzing text with the natural language toolkit*. O'Reilly Media, Inc.
- [9] Jurafsky, D., & Martin, J. H. (2020). *Speech and language processing* (3rd ed. draft). Pearson.
- [10] Zhang, L., Wang, S., & Liu, B. (2018). Deep learning for sentiment analysis: A survey. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 8(4), e1253.
- [11] Socher, R., et al. (2013). Recursive deep models for semantic compositionality over a sentiment treebank. *Proceedings of EMNLP*, 1631-1642.
- [12] Kim, Y. (2014). Convolutional neural networks for sentence classification. *Proceedings of EMNLP*, 1746-1751.
- [13] Devlin, J., et al. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT*, 4171-4186.
- [14] Xu, A., Liu, Z., Guo, Y., Sinha, V., & Akkiraju, R. (2017). A new chatbot for customer service on social media. *Proceedings of CHI*, 3506-3510.
- [15] Følstad, A., & Brandtzæg, P. B. (2017). Chatbots and the new world of HCI. *interactions*, 24(4), 38-42.
- [16] Martínez-Cámara, E., et al. (2020). Overview of TASS 2020: Introducing emotion detection. *Proceedings of IberLEF*, 1-8.